Analisis Komparatif Arsitektur CNN (ResNet-50 vs. MobileNetV2) untuk Klasifikasi Citra Fine-Grained pada Sub-Motif Batik Rumpun Parang

Dibuat untuk memenuhi tugas mata kuliah Metode Penelitian

Dosen Pengampu: Dewi Indriati Hadi Putri, S.Pd., M.T.



Disusun oleh:

Muhammad Afnan Risandi

2301021

PROGRAM STUDI MEKATRONIKA DAN KECERDASAN BUATAN

UNIVERSITAS PENDIDIKAN INDONESIA

KAMPUS DAERAH PURWAKARTA

2025

BAB 1: PENDAHULUAN

Pada bab ini dijelaskan latar belakang penelitian yang memaparkan alasan, urgensi, serta dasar dilaksanakannya penelitian. Selain itu, bab ini juga mencakup rumusan masalah, tujuan penelitian, batasan penelitian, dan manfaat penelitian yang berfungsi sebagai pedoman serta arah dalam pelaksanaan dan pembahasan penelitian secara keseluruhan.

1.1 Latar Belakang Masalah

Batik merupakan warisan budaya takbenda (*intangible cultural heritage*) Indonesia yang telah diakui oleh UNESCO pada tanggal 2 Oktober 2009. Lebih dari sekadar kain bermotif, batik memiliki kekayaan filosofis yang terwujud dalam keragaman corak yang sangat luas, di mana setiap goresan merepresentasikan nilai luhur dan identitas masyarakat pembuatnya. Di era transformasi digital saat ini, upaya pelestarian batik tidak lagi terbatas pada penyimpanan fisik, melainkan telah merambah ke preservasi digital dan katalogisasi cerdas berbasis teknologi . Namun, keragaman motif yang masif ini menghadirkan tantangan tersendiri dalam pengenalan pola secara komputasi. Tantangan terbesarnya bukan sekadar membedakan motif secara umum (*generic classification*), melainkan melakukan identifikasi secara spesifik dan mendetail (*fine-grained classification*). Kemampuan identifikasi mendetail ini menjadi esensial untuk menjaga keaslian, melindungi Hak Kekayaan Intelektual (HAKI), serta mempertahankan nilai filosofis spesifik dari setiap varian corak agar tidak tertukar atau hilang maknanya .

Permasalahan mendasar yang sering muncul, namun kerap diabaikan dalam berbagai penelitian komputasi, adalah kesulitan dalam membedakan sub-motif yang berasal dari satu rumpun yang sama (intra-class). Klasifikasi citra fine-grained (FGIA/FGIR) menargetkan analisis objek visual dari kategori subordinat yang memiliki tingkat kemiripan visual sangat tinggi. Tantangan ini muncul akibat fenomena small inter-class variations (perbedaan antar-kelas yang sangat tipis) dan large intra-class variations (variasi dalam satu kelas yang besar) yang disebabkan

oleh distorsi pola, perbedaan skala, atau kondisi pencahayaan saat pengambilan citra.

Sebagai studi kasus yang krusial, Rumpun Batik Parang memiliki kompleksitas tersebut. Bagi masyarakat awam, membedakan "Batik Parang" dan "Batik Kawung" (klasifikasi general) relatif mudah karena perbedaan bentuk geometris yang kontras. Namun, tantangan sesungguhnya terletak pada klasifikasi fine-grained dalam membedakan antara sub-motif seperti "Parang Rusak", "Parang Klitik", "Parang Kusumo", hingga "Parang Barong". Sub-motif ini berbagi fitur dasar yang sama, yaitu pola diagonal berulang berbentuk huruf 'S' jalin-menjalin, namun memiliki perbedaan mendasar pada detail ornamen, ketebalan garis, ukuran, dan filosofi penggunaannya. Kesalahan identifikasi pada level ini dapat mereduksi nilai sejarah dan menurunkan akurasi sistem katalogisasi museum digital secara signifikan.

Perkembangan *Computer Vision* (CV), khususnya *Convolutional Neural Network* (CNN), telah menunjukkan keberhasilan dalam klasifikasi citra. Namun, sebagian besar penelitian di bidang batik masih berfokus pada klasifikasi *general* (antar-rumpun). Tugas klasifikasi *fine-grained* (intra-rumpun) jauh lebih menantang karena model AI harus mampu belajar mengenali perbedaan fitur yang sangat halus (*subtle features*), sementara variasi di dalam satu kelas (misal: foto Parang Rusak dalam berbagai pencahayaan) bisa sangat tinggi. Di sinilah teknik *Transfer Learning* menjadi sangat relevan, di mana model *pre-trained* seperti ResNet-50 (yang dikenal kuat dalam ekstraksi fitur mendalam) dapat diadaptasi untuk tugas ini.

Sebagai fondasi teknis, Convolutional Neural Network (CNN) menawarkan arsitektur jaringan saraf yang dirancang khusus untuk mengolah data dengan topologi menyerupai grid. Karakteristik unik ini menjadikannya metode yang sangat ideal dan terbukti sukses secara signifikan dalam menangani kompleksitas data visual pada tugas klasifikasi citra. Banyak penelitian telah membuktikan bahwa CNN mampu mengklasifikasikan motif batik Indonesia dengan akurasi tinggi pada level general (antar-rumpun). Contohnya, (Putri et al., 2021) mencapai akurasi 98% menggunakan CNN sederhana untuk 50 jenis batik, mengungguli

VGG16. (Anggoro et al., 2024) berhasil mengklasifikasikan 9 motif Batik Solo, termasuk Parang Barong, dengan akurasi 97.77% menggunakan CNN 3-layer dan dropout 0.2. Penelitian lain oleh (Gede et al., n.d.) menggunakan ResNet-18 dengan transfer learning mencapai akurasi 88.88% pada dataset batik yang telah diperbaiki. Sementara (Hardirega, 2024) mengeksplorasi penggunaan EfficientNet-B1 yang menunjukkan bahwa model kompleks mampu menangkap fitur batik dengan baik. (Akbar et al., n.d.) menggunakan MobileNetV2 dengan transfer learning untuk 3 kelas batik (Kawung, Mega Mendung, Parang) dan mencapai akurasi tes 89.16%. (Muriagista & Kurniadi, n.d.) menerapkan ResNet50 untuk 4 kelas batik (Corak Insang, Dayak, Ikat Celup, Megamendung) dan memperoleh akurasi 81%. Penelitian lain oleh ((Azmi et al., n.d.)) menerapkan CNN untuk klasifikasi Batik Tanah Liat Sumatera Barat dan mencatat akurasi pelatihan hingga 98.75%. (Budimansyah et al., 2025a) juga menunjukkan keberhasilan EfficientNetB0 untuk 20 kelas batik dengan akurasi 82.5%. Keberhasilan CNN juga terlihat pada klasifikasi warisan budaya lain seperti kain tenun Malaka (akurasi 80% dengan VGG16), tokoh wayang Kurawa (akurasi 89.5%) dan bahkan klasifikasi keris. Namun, tugas klasifikasi fine-grained (intra-rumpun) jauh lebih menantang karena memerlukan model untuk menangkap fitur lokal yang halus dan diskriminatif. Pendekatan seperti transfer learning, yang memanfaatkan pengetahuan dari model yang telah dilatih pada dataset besar (misal ImageNet), menjadi sangat relevan. Teknik ini memungkinkan adaptasi model pre-trained seperti ResNet50 yang dikenal kuat dalam ekstraksi fitur mendalam dan mengatasi masalah vanishing gradient atau MobileNetV2 yang efisien untuk perangkat mobile untuk tugas spesifik FGIR batik.

Celah penelitian (research gap) yang signifikan adalah minimnya studi yang secara khusus menangani masalah klasifikasi fine-grained pada sub-motif batik di Indonesia. Penelitian-penelitian sebelumnya, seperti yang telah disebutkan (misalnya), telah fokus pada klasifikasi general antar motif atau antar daerah. Bahkan, penelitian yang spesifik membahas rumpun Parang oleh (Angginy Akhirunnisa Siregar et al., 2023) masih sebatas membedakan "Parang" dari "bukan Parang". (Safira Putri Wulandari, 2020) juga fokus pada pengenalan Parang secara umum menggunakan PCA. Belum ada analisis komparatif mendalam antara model

yang berfokus pada akurasi (seperti ResNet50) dengan model yang lebih efisien (seperti MobileNetV2) untuk tugas klasifikasi fine-grained batik yang spesifik dan sulit ini. Mengingat tantangan unik FGIR, diperlukan pendekatan yang mampu fokus pada detail diskriminatif, mungkin dengan memanfaatkan modul perhatian (attention) atau strategi pembelajaran khusus untuk fitur fine-grained.

Oleh karena itu, penelitian ini diusulkan untuk mengisi celah tersebut. Penelitian ini bertujuan membangun dan menganalisis model *deep learning* untuk klasifikasi *fine-grained* pada sub-motif Batik Rumpun Parang. Dengan membandingkan kinerja arsitektur ResNet-50 dan MobileNetV2, penelitian ini tidak hanya berupaya mencapai akurasi tinggi pada tugas yang sulit, tetapi juga memberikan wawasan tentang arsitektur mana yang paling efektif dan efisien untuk identifikasi detail warisan budaya digital Indonesia.

1.2 Rumusan Masalah

1. Bagaimana merancang arsitektur model CNN menggunakan *transfer learning* (ResNet-50 dan MobileNetV2) untuk tugas klasifikasi *fine-grained* dalam membedakan sub-motif Batik Rumpun Parang?
2. Bagaimana membangun dataset citra *fine-grained* yang teranotasi untuk sub-motif Batik Rumpun Parang (contoh: Parang Rusak, Parang Klitik, Parang Kusumo) untuk kebutuhan pelatihan model?
3. Seberapa tinggi tingkat akurasi, presisi, *recall*, dan *F1-score* dari model ResNet-50 dan MobileNetV2 dalam memecahkan masalah klasifikasi *fine-grained* dengan tingkat kemiripan antar-kelas yang tinggi ini?
4. Bagaimana hasil perbandingan performa (akurasi vs. efisiensi komputasi) antara ResNet-50 dan MobileNetV2 pada studi kasus spesifik ini?

1.3 Batasan Masalah

1. Penelitian ini **hanya berfokus** pada klasifikasi *fine-grained* (sub-motif) dari **satu rumpun batik**, yaitu Rumpun Parang.
2. Sub-motif yang akan diklasifikasikan terbatas pada [3 s/d 4] jenis, contohnya: **Parang Rusak**, **Parang Klitik**, dan **Parang Barong**.

3. Dataset citra dikumpulkan secara mandiri oleh peneliti melalui *web scraping* dan kunjungan ke sentra batik (jika memungkinkan) dan akan melalui proses *cleaning* serta anotasi manual oleh peneliti.
4. Model *transfer learning* yang dibandingkan terbatas pada arsitektur ResNet-50 dan MobileNetV2.
5. Penelitian tidak mencakup teknik *attention mechanism* atau *part-based localization* yang umum pada riset FGIC (Fine-Grained) murni, agar tetap *feasible* untuk S1. Fokusnya adalah *transfer learning* standar pada dataset yang *challenging*.

1.4 Tujuan Penelitian

1. Merancang dan mengimplementasikan model CNN dengan *transfer learning* (ResNet-50 dan MobileNetV2) yang mampu melakukan klasifikasi *fine-grained* pada sub-motif Batik Rumpun Parang.
2. Menghasilkan sebuah dataset *benchmark* baru yang teranotasi untuk penelitian klasifikasi *fine-grained* sub-motif batik.
3. Menganalisis dan mengukur kinerja model menggunakan metrik akurasi, presisi, *recall*, dan *F1-score* pada dataset *fine-grained* yang telah dibangun.
4. Memberikan analisis komparatif objektif mengenai arsitektur mana (ResNet-50 atau MobileNetV2) yang lebih unggul untuk tugas klasifikasi dengan variasi antar-kelas yang rendah.

1.5 Manfaat Penelitian

1. Manfaat Teoritis/Akademis

- Memberikan kontribusi signifikan pada bidang *Computer Vision*, khususnya pada sub-bidang *Fine-Grained Image Classification* (FGIC) dalam konteks pelestarian warisan budaya.
- Menghasilkan dataset *benchmark* baru (sub-motif Parang) yang dapat digunakan oleh peneliti selanjutnya untuk menguji metode klasifikasi *fine-grained* yang lebih canggih.

2. Manfaat Praktis

- Memberikan alat bantu (prototipe) bagi kurator museum, akademisi, dan ahli batik untuk melakukan katalogisasi digital yang lebih detail dan akurat.
- Membantu melindungi HAKI (Hak Kekayaan Intelektual) dan keaslian sub-motif batik yang spesifik di pasar *e-commerce*, dengan membedakannya dari motif serupa atau tiruan.

BAB 2: TINJAUAN PUSTAKA DAN LANDASAN TEORI

2.1 Karakteristik Visual Objek: Batik Parang dalam Perspektif Fine-Grained

2.1.1 Dikotomi Klasifikasi Visual: Tantangan Isomorfisme pada Batik

Klasifikasi citra dalam *Computer Vision* tidak dapat dipandang sebagai entitas homogen. Terdapat jurang kompleksitas yang lebar antara klasifikasi generik (Coarse-*Grained*) dan klasifikasi halus (*Fine-Grained*). Pada klasifikasi generik, perbedaan antar-objek bersifat struktural dan kontras (misalnya: membedakan Batik Kawung yang geometris vs. Batik Parang yang diagonal). Sebaliknya, penelitian ini beroperasi pada domain *Fine-Grained Visual Categorization* (FGVC), di mana tantangannya adalah membedakan sub-kategori yang memiliki struktur topologi identik atau isomorfis. Dalam kasus Rumpun Parang, varians antar-kelas (*inter-class variance*) sangat rendah karena semua varian berbagi fitur dasar yang sama (huruf 'S' jalin-menjalin), sehingga model tidak bisa lagi mengandalkan bentuk global, melainkan harus melakukan ekstraksi fitur pada detail lokal yang subtil (*subtle features*).

A. Klasifikasi Generik (Coarse-Grained): Paradigma Bentuk Global

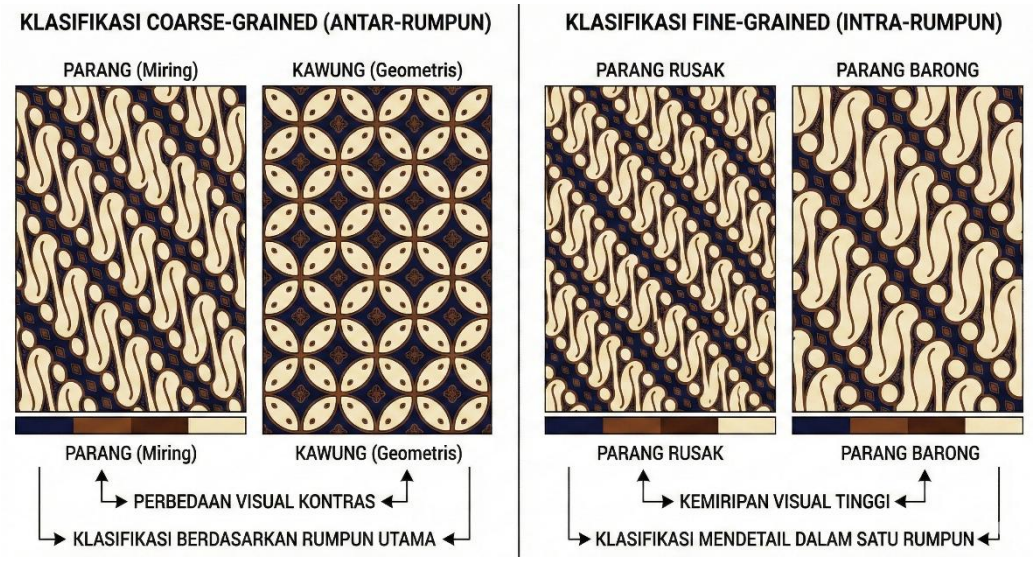
Klasifikasi generik beroperasi pada domain di mana perbedaan antar-kelas bersifat fundamental, struktural, dan geometris. Contoh klasik yang sering digunakan dalam literatur adalah membedakan gedung versus kendaraan, atau kucing versus anjing (seperti pada dataset CIFAR-10). Pada level ini, algoritma mengandalkan fitur visual yang memiliki kontras geometris tinggi. Perbedaan bentuk dasar (*shape*), topologi objek, dan siluet sangat jelas, sehingga model komputasi relatif mudah menarik garis batas keputusan (*decision boundary*) pada ruang fitur (*feature space*). Sebagai ilustrasi, model tidak perlu "memperhatikan" detail tekstur bulu seekor kucing untuk membedakannya dari mobil; cukup dengan mendeteksi bentuk telinga segitiga atau keberadaan roda bundar, klasifikasi sudah dapat

dilakukan dengan akurasi tinggi. Fitur-fitur ini bersifat makroskopis dan mudah diekstraksi bahkan oleh *layer-layer* awal CNN.

B. Klasifikasi Halus (Fine-Grained Visual Categorization / FGVC): Paradigma Detail Mikro

Sebaliknya, *Fine-Grained Visual Categorization* (FGVC) beroperasi pada level kesulitan yang jauh lebih tinggi dan menuntut presisi mikroskopis. FGVC berfokus pada pembedaan sub-kategori dari satu kelas induk (meta-class) yang sama. Dalam domain ini, perbedaannya tidak lagi terletak pada bentuk global atau siluet karena semua objek dalam kelas induk berbagi morfologi yang sama, melainkan pada detail lokal yang sangat subtil, variasi tekstur permukaan, dan proporsi rasio antar bagian-bagian objek. Penelitian ini menempatkan Batik Rumpun Parang sebagai studi kasus FGVC yang representatif dan menantang, setara dengan kompleksitas membedakan spesies burung pada dataset CUB-200-2011.

Berbeda dengan penelitian-penelitian sebelumnya (seperti Putri et al., 2021) yang membandingkan motif antar-rumpun (misalnya Parang vs. Kawung vs. Megamendung) yang memiliki perbedaan struktur visual fundamental, penelitian ini menempatkan Batik Rumpun Parang sebagai studi kasus FGVC yang representatif. Berbeda dengan penelitian-penelitian sebelumnya seperti yang dilakukan oleh (Fadiyah Alya & Wibowo, 2023) yang mengklasifikasikan berbagai motif batik yang berbeda secara visual (antar-rumpun), penelitian ini menghadapi tantangan varians intra-kelas yang ekstrem. Semua varian Parang berbagi "genetika visual" yang sama: fitur global berupa pola lereng diagonal (Pereng) dengan kemiringan 45 derajat dan jalinan motif 'S'. Secara topologi, Parang Rusak dan Parang Barong adalah isomorfis; keduanya memiliki struktur dasar yang identik.



Gambar 2.1.1: Ilustrasi perbedaan konsep klasifikasi *Coarse-Grained* versus *Fine-Grained*. Gambar kiri (*Coarse*) menunjukkan perbedaan kontras tinggi antara Parang dan Kawung. Gambar kanan (*Fine*) menunjukkan tantangan fine-grained di mana Parang Rusak dan Parang Barong memiliki kemiripan struktural yang tinggi, menuntut model untuk fokus pada detail mikro.

Implikasinya, model CNN standar yang cenderung bekerja berdasarkan pengenalan bentuk global (sering disebut sebagai fitur Gestalt) berpotensi gagal total. Model tersebut mungkin dengan mudah mengenali sebuah gambar sebagai "Batik Parang", namun gagal menentukan apakah itu "Parang Rusak" atau "Parang Barong" karena keduanya terlihat identik dari pandangan sekilas (*glance vision*). Tanpa mekanisme yang memaksa model untuk melakukan *scrutiny* (pengamatan mendetail), fitur global yang dominan akan menutupi fitur lokal yang diskriminatif. Hal ini diperparah oleh variasi intra-kelas yang disebabkan oleh faktor eksternal seperti perbedaan teknik pewarnaan, jenis kain, atau kondisi pencahayaan saat digitalisasi, yang seringkali lebih besar daripada perbedaan antar-submotif itu sendiri. Di sinilah urgensi penerapan metode *fine-grained* yang memaksa model memperhatikan fitur lokal (*attention to local features*) menjadi sangat beralasan.

Fenomena ini dapat disandingkan dengan tantangan pada dataset standar FGVC global, seperti CUB-200-2011 (Wah et al., 2011) yang digunakan untuk membedakan 200 spesies burung. Dalam dataset tersebut, perbedaan antar spesies burung camar seringkali hanya terletak pada warna cincin mata atau pola pada ujung sayap. Namun, terdapat perbedaan mendasar yang membuat kasus batik unik dan lebih kompleks secara semantik: jika variasi pada burung bersifat biologis dan evolusioner, variasi pada batik terikat pada pakem budaya yang kaku. Perbedaan antara Parang Rusak dan Parang Barong bukan sekadar masalah stokastik tekstur piksel atau mutasi biologis, melainkan aturan hierarkis yang ketat mengenai ukuran (skala), ketebalan garis lilin (canting), dan keberadaan ornamen isen-isen yang memiliki makna simbolis tertentu. Model komputasi yang dibangun harus mampu mengadopsi "aturan pakem" ini dengan menerjemahkannya ke dalam representasi fitur matematis yang presisi, menjembatani kesenjangan semantik (*semantic gap*) antara data piksel digital dan makna budaya yang terkandung di dalamnya.

2.1.2 Spesifikasi Varian Parang sebagai Datase

Untuk keperluan komputasi yang akurat, karakteristik visual varian Parang harus didefinisikan secara operasional dan terukur. Pendefinisian ini penting untuk memahami fitur apa yang diharapkan dapat dipelajari oleh model *Deep Learning*. Berikut adalah dekonstruksi visual mendalam dari varian yang menjadi fokus penelitian:

1. **Parang Rusak:** Varian ini memiliki ciri morfologi motif 'S' yang saling menjalin tanpa putus, menyimbolkan kesinambungan perjuangan manusia melawan hawa nafsu. Secara visual, tantangan utama bagi model adalah mendeteksi keberadaan ornamen mlinjon (bentuk belah ketupat) yang proporsional di antara jalinan motif utama.
    - Model harus mampu memisahkan tekstur mlinjon ini dari noise latar belakang kain. Pada batik tulis asli, seringkali terdapat

retakan lilin (*wax crackles*) atau ketidaksempurnaan pewarnaan yang bisa disalahartikan sebagai fitur. Selain itu, model harus membedakannya dari isen-isen dekoratif lain yang tidak bermakna struktural (seperti cecek atau titik-titik). Kegagalan mendeteksi mlinjon secara spesifik akan menyebabkan ambiguitas klasifikasi dengan varian parang polos lainnya atau parang curigo.

2. **Parang Barong**: Secara topologi bentuk, Parang Barong sangat mirip bahkan hampir identik dengan Parang Rusak. Keduanya memiliki jalinan 'S' dan ornamen mlinjon. Varian ini didefinisikan oleh dimensi motif yang dominan dan garis tebal (*low spatial frequency*). Tantangan utamanya adalah risiko ambiguitas akibat proses *resizing* pada preprocessing CNN, yang berpotensi menghilangkan informasi ukuran relatif motif.
    - Tantangan terbesar di sini adalah masalah invarian skala. Dalam pengolahan citra digital modern, model sering dilatih dengan augmentasi data yang mencakup *resizing* dan *cropping*, yang secara tidak sengaja mengajarkan model untuk mengabaikan ukuran objek *(scale-invariant*). Namun, untuk Parang Barong, ukuran adalah fitur penentu. Penelitian ini menuntut model untuk bersifat *scale-aware* (mampu menjadikan ukuran relatif fitur terhadap bidang gambar sebagai penentu kelas). Model harus belajar asosiasi fitur non-linear: "Bentuk Parang Rusak" + "Ukuran Besar/Garis Tebal" → "Parang Barong".
3. **Parang Klitik**: Varian ini merepresentasikan kehalusan, kebijaksanaan, dan feminitas. Ciri visual utamanya adalah pola dengan frekuensi spasial tinggi (kerapatan motif padat) dan ukuran motif yang kecil serta pipih (gepeng). Dicirikan oleh kerapatan motif yang tinggi (*high spatial frequency*) dan ukuran pipih. Model memerlukan *receptive field* yang cukup sensitif untuk menangkap tekstur padat ini tanpa mengalami *aliasing* atau *blurring* pada layer konvolusi terdalam.

- Karakteristik ini menuntut model memiliki *receptive field* yang efektif untuk menangkap detail frekuensi tinggi. Risiko utamanya adalah fenomena aliasing atau hilangnya informasi detail saat citra mengalami proses *downsampling* (*pooling*) bertingkat di dalam layer-layer CNN. Jika resolusi fitur map pada layer terdalam terlalu kecil, motif Parang Klitik bisa terlihat seperti blur atau tekstur acak, sehingga model gagal mengidentifikasinya. Hal ini menjadi argumen kuat untuk mempertimbangkan arsitektur yang mempertahankan resolusi spasial atau memiliki mekanisme *skip connection* yang efektif.



Gambar 2.1.2: Komparasi visual morfologi sub-motif Parang. (A) Parang Rusak dengan detail isen-isen mlinjon; (B) Parang Barong dengan skala motif yang dominan dan garis tebal; (C) Parang Klitik dengan motif pipih dan rapat. Perhatikan perbedaan skala dan frekuensi spasial yang menjadi tantangan komputasi.

Sumber: https://www.gramedia.com/best-seller/batik-parang/(diakses 2025) dan Anotasi Penulis.

2.1.3 Pemanfaatan Repositori Data Sekunder: Single-Family Dataset Strategy

Penelitian ini secara sadar mengadopsi strategi *Single-Family Dataset*, yaitu membatasi domain data hanya pada satu rumpun motif

(Parang) tanpa mencampurkan rumpun lain (seperti Ceplok atau Semen). Keputusan ini didasarkan pada prinsip isolasi variabel: dengan menghilangkan varians antar-rumpun yang ekstrem, penelitian dapat mengisolasi kemampuan model dalam menangkap fitur *fine-grained* murni.

Data citra dikurasi dari repositori publik yang tersedia, secara spesifik menggabungkan dua sumber dataset terkurasi (Zun Afif & Dionisius Darryl) yang berfokus pada varian Parang. Penggunaan data sekunder dari repositori terbuka (*open-source repositories*) dalam penelitian Deep Learning memiliki justifikasi metodologis yang kuat:

1. **Benchmarking**: Memungkinkan hasil penelitian ini dibandingkan dengan studi lain yang menggunakan sumber serupa di masa depan.
2. **Fokus pada Algoritma:** Dengan menggunakan data yang sudah tersedia, fokus penelitian dapat dialihkan secara maksimal pada optimasi arsitektur model dan analisis *hyperparameter*, bukan pada proses akuisisi citra fisik yang memakan waktu.
3. **Tantangan Heterogenitas**: Penggabungan dua sumber yang berbeda (meskipun sama-sama Parang) memperkenalkan tantangan nyata berupa heterogenitas kondisi pencahayaan dan resolusi kamera, yang menguji ketahanan (*robustness*) model terhadap domain bias.

2.2 Landasan Teori Deep Learning

2.2.1 Evolusi Ekstraksi Fitur: Keterbatasan Hand-Crafted Features

Sebelum dominasi *Deep Learning* pada dekade terakhir, analisis citra digital, termasuk batik, sangat bergantung pada metode ekstraksi fitur manual (*hand-crafted features*). Dua metode yang paling sering dirujuk dalam literatur adalah GLCM dan SIFT. Penting untuk membedah mekanisme kerja keduanya untuk memahami mengapa transisi ke CNN adalah sebuah keniscayaan evolusioner dalam *computer vision*.

A. **Gray Level Co-occurrence Matrix (GLCM)** adalah metode statistik orde kedua yang dikembangkan oleh (HARALICK et al., 1973) untuk analisis tekstur. Metode ini masih banyak digunakan dalam penelitian batik lokal, seperti oleh (Ananda & Irma, 2024)

   - GLCM bekerja dengan menghitung probabilitas kemunculan pasangan piksel dengan nilai intensitas tertentu pada jarak (d) dan sudut (θ) tertentu. Dari matriks probabilitas ini, diturunkan parameter statistik seperti *Contrast, Correlation, Energy,* dan *Homogeneity*.

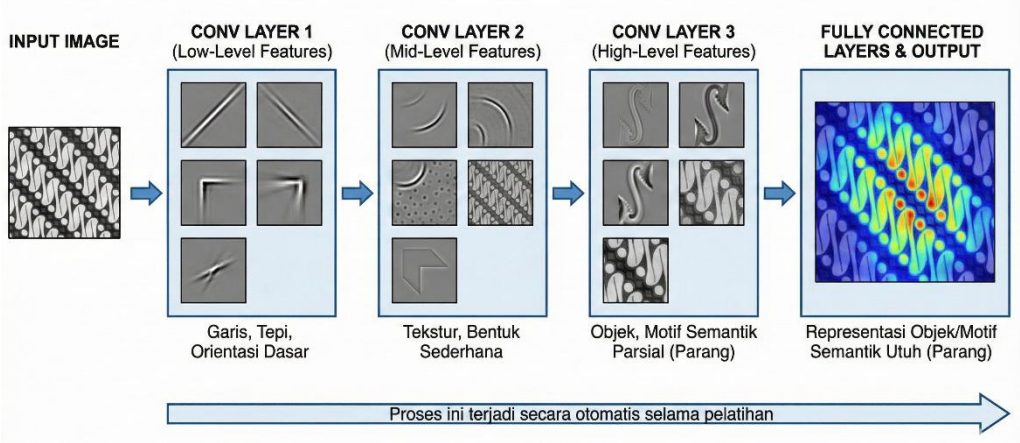
   - GLCM hanya melihat statistik permukaan. Tidak memiliki konsep "objek" atau "bentuk". GLCM bisa membedakan tekstur kasar vs halus, tetapi kesulitan membedakan bentuk lengkungan 'S' Parang dengan lingkaran 'O' Kawung jika distribusi intensitas pikselnya mirip. Ini disebut sebagai *semantic gap*. Dalam studi (Ananda & Irma, 2024) terbukti bahwa akurasi GLCM (82%) tertinggal jauh dari CNN (94%) pada dataset batik yang sama.

B. **Scale-Invariant Feature Transform** (SIFT) adalah algoritma deteksi fitur lokal yang diperkenalkan oleh (Lowe, 2004)

   - SIFT bekerja dengan mendeteksi keypoints (titik kunci) yang stabil terhadap perubahan skala dan rotasi, kemudian mendeskripsikannya menggunakan histogram orientasi gradien.
   - SIFT sangat tangguh untuk instance matching (mencocokkan dua foto dari objek yang sama persis), namun lemah dalam category classification (mengenali kategori objek yang bervariasi). Variasi goresan tangan pada batik tulis membuat setiap motif memiliki *keypoints* yang sedikit berbeda, sehingga SIFT sering gagal melakukan generalisasi kategori.

C. **Convolutional Neural Networks (CNN)** Berbeda dengan GLCM dan SIFT yang fiturnya ditentukan oleh manusia, CNN menggunakan pendekatan Feature Learning.

- Melalui algoritma Backpropagation, CNN secara otomatis mempelajari filter (kernel) terbaik langsung dari data piksel.
- CNN membangun hierarki fitur. Layer awal belajar mendeteksi garis (seperti SIFT), layer tengah belajar tekstur (seperti GLCM), dan layer akhir belajar konsep semantik (Motif). Kemampuan belajar hierarkis inilah yang membuat CNN superior untuk tugas Fine-Grained.



Gambar 2.2.3: Skema arsitektur CNN yang menunjukkan evolusi ekstraksi fitur dari Low-Level (garis/tepi) menuju High-Level (objek/motif semantik). Proses ini terjadi secara otomatis selama pelatihan.

Sumber: Diadaptasi dari LeCun et al. (2015).

2.2.2 Konsep Transfer Learning dan Adaptasi Domain

Salah satu hambatan terbesar dan paling persisten dalam penerapan *Deep Learning* untuk pelestarian warisan budaya di negara berkembang adalah kelangkaan data terkurasi (data *scarcity*). Melatih model CNN modern yang memiliki jutaan parameter (seperti ResNet-50 dengan ~25 juta parameter) dari awal (*training from scratch*) membutuhkan dataset masif

untuk mencapai konvergensi yang stabil dan menghindari bias varians. Mengingat keterbatasan jumlah data citra batik teranotasi yang tersedia (biasanya dalam orde ratusan atau ribuan) dibandingkan dengan dataset raksasa seperti ImageNet (1.2 juta citra), pelatihan dari nol berisiko tinggi menyebabkan *overfitting*. *Overfitting* adalah kondisi patologis di mana model "menghafal" data latih (termasuk *noise*, artefak kompresi, dan latar belakang yang tidak relevan) namun gagal mengenali pola umum, sehingga performanya anjlok saat diuji pada data baru yang belum pernah dilihat sebelumnya.

Penelitian ini mengatasi kendala tersebut dengan menerapkan strategi Transfer Learning (Pan & Yang, 2010) Metode ini memanfaatkan "pengetahuan visual" (bobot model) yang telah dilatih pada dataset sumber (source domain) yang besar seperti ImageNet untuk menyelesaikan tugas pada domain target (target domain) yaitu Batik. Sebagaimana dijelaskan oleh (Fadiyah Alya & Wibowo, 2023), penggunaan model pre-trained sangat krusial untuk mengatasi masalah overfitting pada dataset batik yang memiliki variasi corak tinggi namun jumlah sampel terbatas.

Secara teoretis, *Transfer Learning* bekerja berdasarkan asumsi Inductive Transfer, di mana layer-layer awal pada CNN mempelajari fitur visual universal yang agnostik terhadap domain. Garis vertikal pada foto gedung di ImageNet memiliki karakteristik matematis (gradien piksel) yang sama dengan garis vertikal pada motif batik, meskipun objek semantiknya berbeda. Oleh karena itu, filter pendeteksi garis yang sudah terlatih dapat langsung digunakan kembali tanpa perlu dipelajari ulang dari awal. Hal ini menghemat waktu komputasi secara drastis dan memungkinkan model mencapai performa tinggi meski dengan data latih yang sedikit.

Proses adaptasi domain dilakukan melalui mekanisme fine-tuning bertahap:

1. **Frozen Layers (Ekstraksi Fitur Statis):** Bobot pada layer-layer awal (ekstraktor fitur dasar) dibekukan (*frozen*), artinya gradien tidak dihitung

untuk layer ini selama fase *backward pass*. Tujuannya adalah menjaga kemampuan model mendeteksi fitur universal tanpa merusaknya dengan gradien yang bising dari dataset batik yang kecil.

2. **Trainable Layers (Adaptasi Semantik):** Layer-layer akhir (ekstraktor fitur semantik tingkat tinggi) dan *classifier head* (lapisan *fully connected* terakhir) dilatih ulang (*unfrozen*) dengan laju pembelajaran (*learning rate*) yang sangat kecil. Langkah ini bertujuan untuk "menyetel ulang" representasi fitur tingkat tinggi agar sensitif terhadap karakteristik unik Batik Parang. Proses ini secara efektif mengubah pemahaman model dari mengenali objek umum (seperti mobil, anjing, atau buah) menjadi mengenali motif spesifik budaya (Parang Rusak, Parang Barong).

2.2.3 Data Augmentation sebagai Regularisasi Geometris

Dalam skenario data terbatas (*low-resource regime*), model CNN rentan mengalami bias posisi atau orientasi (*positional bias*). Karena CNN standar tidak secara inheren invarian terhadap rotasi (kecuali rotasi kecil), model mungkin secara keliru mengasosiasikan label "Parang Rusak" hanya dengan posisi motif yang tegak lurus vertikal. Padahal, dalam realitasnya, kain batik bisa dipakai di tubuh manusia (mengikuti lekuk tubuh), dipajang miring, dilipat, atau difoto dari berbagai sudut pandang yang ekstrem.

(Negara et al., 2021) dalam penelitiannya tentang ResNet-50 untuk batik membuktikan bahwa teknik augmentasi data (rotasi, flip) secara signifikan meningkatkan kemampuan generalisasi model dengan memperbanyak variasi data latih secara sintetik. ***Data Augmentation*** diterapkan sebagai bentuk regularisasi geometris untuk memitigasi risiko ini dan meningkatkan kemampuan generalisasi model. Teknik ini secara artifisial memperluas variasi, volume, dan keragaman data latih melalui transformasi citra stokastik tanpa mengubah label semantiknya. Ini memaksa model untuk belajar fitur yang lebih robust.

Beberapa teknik augmentasi krusial yang diimplementasikan meliputi:

- **Rotasi Acak (*Random Rotation*):** Teknik ini sangat krusial untuk data batik karena motif batik seringkali bersifat repetitif dan tidak memiliki orientasi "atas-bawah" yang mutlak seperti wajah manusia atau mobil. Dengan melatih model pada citra yang diputar 30°, 45°, atau 90°, model dipaksa untuk belajar fitur motif itu sendiri, bukan orientasinya.
- **Pembalikan Sumbu (*Horizontal/Vertical Flip*):** Mengajarkan model simetri pola, memastikan bahwa motif parang yang menghadap ke kiri dikenali sama baiknya dengan yang menghadap ke kanan.
- **Penyesuaian Kecerahan dan Kontras (*Color Jitter*):** Mensimulasikan kondisi pengambilan gambar yang tidak ideal di lapangan, seperti pencahayaan museum yang redup, penggunaan *flash* kamera yang menyebabkan silau, atau pudar warna karena usia kain. Augmentasi ini memaksa model untuk mempelajari fitur struktural motif (bentuk dan tekstur) daripada bergantung pada intensitas warna absolut atau nilai RGB spesifik (*invariant features*).

2.2.4 Lingkungan Eksperimental dan Perangkat Lunak: Google Colaboratory

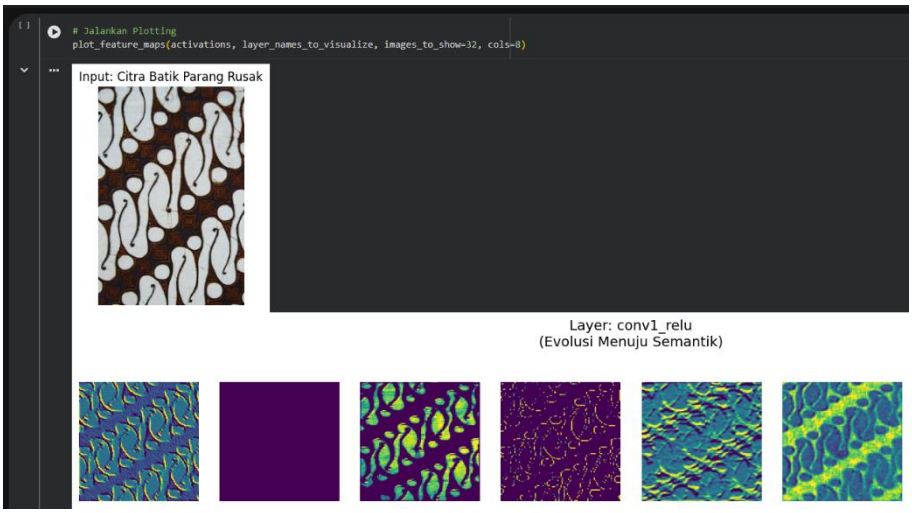
Untuk memastikan validitas eksperimental dan memungkinkan pelatihan model arsitektur dalam (*deep architecture*) seperti ResNet-50 yang membutuhkan sumber daya komputasi intensif, penelitian ini memanfaatkan platform Google Colaboratory (sering disebut sebagai Google Colab). Google Colab adalah lingkungan penelitian berbasis cloud yang menyediakan akses gratis terhadap infrastruktur komputasi kinerja tinggi (Bisong, 2019)

Pemilihan Google Colab sebagai perangkat lunak eksperimen didasarkan pada tiga justifikasi teknis utama:

1. **Akselerasi Perangkat Keras (GPU T4):** Pelatihan CNN melibatkan jutaan operasi perkalian matriks (*floating point operations* - FLOPS) dalam setiap *epoch*. Google Colab menyediakan akses ke GPU NVIDIA Tesla T4 yang memiliki ribuan *CUDA cores*. Penggunaan

GPU ini mempercepat proses pelatihan (*training time*) dari skala hari (jika menggunakan CPU laptop standar) menjadi skala jam. Hal ini memungkinkan peneliti melakukan iterasi eksperimen (tuning *hyperparameter*) dengan lebih efisien.

2. **Lingkungan Terstandarisasi:** Colab menyediakan lingkungan *runtime* Python yang telah terkonfigurasi dengan pustaka *Deep Learning* standar industri seperti **TensorFlow** dan **Keras**. Hal ini menjamin reproduksibilitas penelitian (*reproducibility*), di mana kode eksperimen dapat dijalankan ulang oleh peneliti lain dengan konfigurasi pustaka yang identik, mengurangi risiko eror akibat perbedaan versi perangkat lunak.
3. **Visualisasi Metrik Real-Time:** Platform ini mendukung visualisasi grafik pelatihan (kurva *Loss* dan *Accuracy*) secara *real-time* menggunakan pustaka seperti Matplotlib atau TensorBoard langsung di dalam *notebook*. Fitur ini krusial untuk mendeteksi gejala *overfitting* atau *underfitting* secara dini selama proses pelatihan model ResNet dan MobileNet.



Gambar 2.4: Ilustrasi antarmuka lingkungan kerja Google Colaboratory yang menampilkan batik dan eksekusi kode pelatihan model menggunakan TensorFlow/Keras.

Sumber: Tangkapan Layar Lingkungan Eksperimen Penulis (2025).

2.3 Analisis Komparatif Arsitektur CNN

Pemilihan arsitektur model dalam penelitian ini bukan sekadar preferensi teknis semata, melainkan perbandingan head-to-head antara dua filosofi desain jaringan saraf yang berbeda secara fundamental: prioritas pada kedalaman representasi (*Depth*) yang diwakili oleh ResNet, versus prioritas pada efisiensi komputasi (*Efficiency*) yang diwakili oleh MobileNet.

2.3.1 ResNet-50 (Deep Residual Learning)

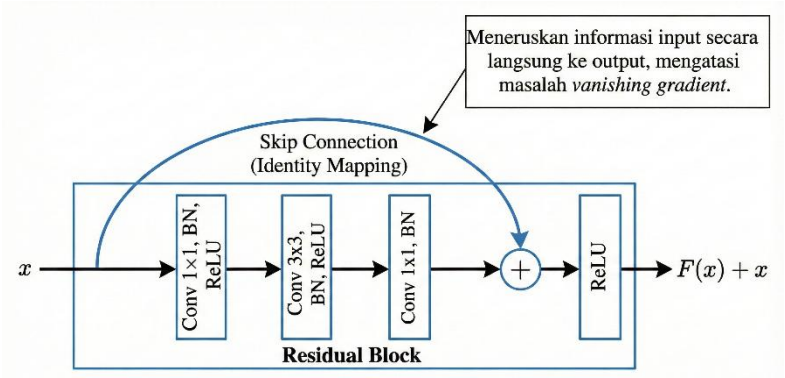
Arsitektur ResNet-50, yang dikembangkan oleh (He et al., 2016) menjadi tonggak sejarah revolusioner dalam dunia Deep Learning karena keberhasilannya memungkinkan pelatihan jaringan yang sangat dalam (*very deep networks*) hingga ratusan layer. Sebelum era ResNet, menambah kedalaman jaringan seringkali justru menurunkan akurasi, bukan meningkatkannya. Tantangan utama pada jaringan dalam konvensional adalah masalah *vanishing gradient* (gradien menghilang). Dalam konteks batik, (Negara et al., 2021) telah mengimplementasikan ResNet-50 untuk klasifikasi 50 kelas batik Indonesia dan menunjukkan bahwa arsitektur ini sangat andal dalam menangkap fitur kompleks dengan stabilitas tinggi, terutama ketika dikombinasikan dengan augmentasi data. Kedalaman ResNet-50 memberikan kapasitas representasi besar untuk membedakan detail fine-grained pada ornamen Parang.

Secara matematis, gradien error dihitung menggunakan aturan rantai (*chain rule*) dari layer output mundur ke layer input selama proses *backpropagation*. Pada jaringan yang sangat dalam, gradien di *layer* awal adalah hasil perkalian berulang dari matriks Jacobian *layer-layer* di atasnya. Karena fungsi aktivasi (seperti Sigmoid atau Tanh) dan inisialisasi bobot seringkali menghasilkan nilai turunan yang kecil (kurang dari 1), perkalian berulang ini menyebabkan nilai gradien menyusut secara eksponensial mendekati nol saat mencapai layer awal. Akibatnya, bobot pada layer awal tidak diperbarui secara signifikan, *layer* tersebut berhenti belajar, dan akurasi model mengalami degradasi (*degradation problem*).

ResNet memecahkan masalah degradasi ini dengan memperkenalkan *Residual Block* yang menggunakan koneksi shortcut (jalan pintas) atau *skip connection*. Alih-alih memaksa layer untuk mempelajari pemetaan fitur yang diinginkan *H(x)* secara langsung, blok residual memodelkan pemetaan tersebut sebagai penjumlahan dari fungsi residual dan input identitas:

Di mana $F(x)$ adalah fungsi residual (perbedaan antara input dan output yang diinginkan) yang dipelajari oleh tumpukan layer konvolusi, dan x adalah input identitas dari layer sebelumnya. Koneksi identitas $+x$ memungkinkan sinyal gradien mengalir langsung dari output ke input tanpa hambatan operasi non-linear atau perkalian matriks yang mereduksi nilai, bertindak sebagai "jalan tol" informasi. Hal ini memungkinkan jaringan mencapai kedalaman 50 *layer* (pada ResNet-50) tanpa kehilangan kemampuan belajar pada layer-layer awal.

Selain itu, ResNet-50 menggunakan desain *Bottleneck Block*, yang terdiri dari tiga lapisan konvolusi berurutan (1x1, 3x3, 1x1). Konvolusi 1x1 pertama digunakan untuk mengurangi dimensi kanal (kompresi) sebelum dilakukan konvolusi spasial 3x3 yang mahal secara komputasi, dan konvolusi 1x1 terakhir mengembalikan dimensi ke ukuran semula (ekspansi). Struktur ini secara signifikan meningkatkan efisiensi parameter sembari mempertahankan kedalaman jaringan. Dalam konteks batik, kedalaman 50 layer ini memberikan kapasitas representasi (*representational capacity*) yang jauh lebih besar untuk mengekstraksi dan menyusun fitur semantik kompleks secara hierarkis, yang sangat diperlukan untuk membedakan detail fine-grained yang ambigu pada motif Parang.



Gambar 2.5: Diagram struktur blok residual pada ResNet-50. Panah melengkung menunjukkan skip connection yang meneruskan informasi input secara langsung ke output, mengatasi masalah vanishing gradient.

2.3.2 MobileNetV2 (Efficient Convolution)

Di sisi lain spektrum desain, MobileNetV2 yang dikembangkan oleh (Sandler et al., 2018) didesain dengan filosofi "Mobile First". Arsitektur ini ditujukan secara eksplisit untuk aplikasi pada perangkat dengan sumber daya komputasi dan memori terbatas (*resource-constrained devices*), seperti smartphone kelas menengah, tablet, atau perangkat IoT yang umum digunakan dalam inventarisasi lapangan atau aplikasi museum digital.

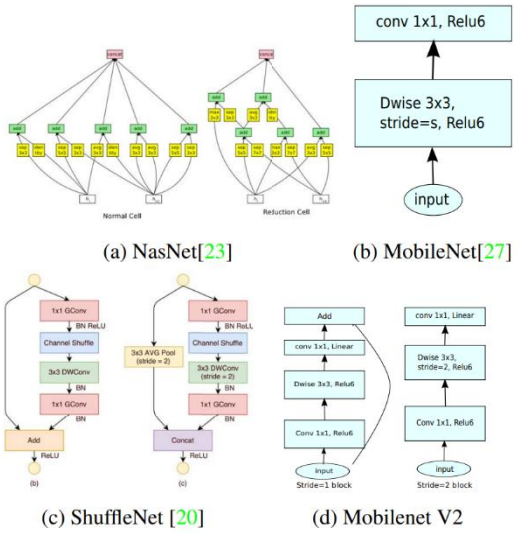
Kontribusi revolusioner MobileNetV2 adalah penggunaan *Depthwise Separable Convolution*. Metode ini memecah operasi konvolusi standar 3x3 yang berat secara komputasi menjadi dua tahap faktorisasi yang jauh lebih ringan:

1. **Depthwise Convolution:** Melakukan penyaringan spasial ringan, di mana satu filter konvolusi diterapkan hanya pada satu kanal *input*. Ini menangkap fitur spasial (bentuk, tekstur) tanpa menggabungkan informasi antar-kanal, sehingga mengurangi beban komputasi secara drastis.
2. **Pointwise Convolution:** Melakukan kombinasi linear antar kanal menggunakan konvolusi 1x1. Tahap ini bertugas menggabungkan

informasi fitur yang telah disaring secara spasial untuk membentuk fitur baru yang lebih kompleks.

Pendekatan faktorisasi ini secara teoritis mengurangi beban komputasi (diukur dalam *Floating Point Operations* atau FLOPS) dan jumlah parameter hingga 8-9 kali lipat dibandingkan konvolusi standar 3x3 dengan jumlah filter yang sama. Selain itu, MobileNetV2 memperkenalkan struktur inovatif bernama *Inverted Residuals*. Berbeda dengan ResNet yang menggunakan struktur "lebar-sempit-lebar" pada blok bottleneck (kompresi di tengah), MobileNetV2 menggunakan struktur "sempit-lebar-sempit". *Layer bottleneck input* yang berdimensi rendah diekspansi ke dimensi tinggi di dalam blok untuk diproses oleh *depthwise convolution* (menggunakan fungsi aktivasi ReLU6 untuk stabilitas numerik), lalu diproyeksikan kembali ke dimensi rendah (menggunakan aktivasi linear untuk mencegah hilangnya informasi) guna menghemat memori.

Meskipun menawarkan kecepatan inferensi yang superior dan ukuran model yang kecil, terdapat potensi *trade-off* teoretis yang perlu diuji. Kompresi informasi pada layer bottleneck yang sempit berpotensi menyebabkan hilangnya informasi detail mikroskopis atau fitur frekuensi tinggi yang krusial untuk klasifikasi fine-grained. Hipotesis mengenai seberapa signifikan penurunan akurasi ini demi mendapatkan efisiensi adalah salah satu inti investigasi penelitian ini, terutama dalam konteks pelestarian budaya di mana detail adalah segalanya.



Gambar 2.5: Perbandingan struktur blok konvolusi standar (kiri) dengan *Depthwise Separable Convolution* pada MobileNetV2 (kanan), menunjukkan efisiensi operasi.

(Sumber: (Sandler et al., 2018))

2.4 Metrik Evaluasi Model

Evaluasi kinerja model klasifikasi fine-grained pada warisan budaya memerlukan metrik yang komprehensif, multidimensi, dan kontekstual. Mengandalkan akurasi global semata dapat menyesatkan (*misleading*), terutama jika distribusi data antar-kelas tidak seimbang (*imbalanced dataset*), yang sering terjadi pada koleksi museum.

1. **Akurasi (Accuracy):** Mengukur rasio prediksi benar secara keseluruhan terhadap total sampel.

$$Accuracy = \frac{TP + TN}{Total\ Samples}$$

Metrik ini memberikan gambaran umum kesehatan model, namun kurang sensitif terhadap kesalahan pada kelas minoritas. Dalam kasus data tidak seimbang (misal: Parang Rusak mendominasi 80% data), model yang bias ke kelas mayoritas bisa tetap memiliki

akurasi tinggi meskipun gagal total mengenali kelas minoritas (Parang Klitik).

2. **Presisi (Precision):** Mengukur tingkat keandalan (*trustworthiness*) prediksi positif model. Rumusnya adalah:

$$Precision = \frac{TP}{TP + FP}$$

Presisi tinggi berarti model memiliki tingkat *False Positive* yang rendah.

- Dalam konteks aplikasi katalogisasi komersial atau marketplace batik, presisi tinggi sangat penting agar sistem tidak "berbohong" dengan melabeli batik biasa sebagai motif langka (misal: Parang Barong). Kesalahan ini dapat merusak kredibilitas sistem di mata pakar, kolektor, atau pembeli, serta berpotensi menimbulkan kerugian ekonomi.

3. **Recall (Sensitivitas):** Mengukur kemampuan model menemukan kembali seluruh *instance* positif yang ada dalam dataset.
Rumusnya adalah:

$$Recall = \frac{TP}{TP + FN}$$

- Metrik ini sangat krusial dalam konteks pelestarian dan pencarian (*retrieval*) budaya digital. Nilai *Recall* yang tinggi mengindikasikan kemampuan sistem untuk mendeteksi keberadaan motif tertentu dalam database museum tanpa banyak yang terlewat (*False Negative*). Dalam preservasi budaya, kehilangan deteksi pada motif warisan (gagal mengidentifikasi artefak berharga karena dianggap noise atau kelas lain) seringkali dianggap kesalahan yang lebih fatal daripada kesalahan identifikasi yang bisa diverifikasi ulang

(positif palsu). Kita lebih memilih sistem yang sedikit "cerewet" (menandai banyak kandidat) daripada sistem yang "abai".

4. **F1-Score**: Merupakan rata-rata harmonik antara Presisi dan Recall.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

- Metrik ini memberikan gambaran keseimbangan performa model. Dalam kasus fine-grained di mana kemiripan visual sangat tinggi, F1-Score menjadi indikator terbaik untuk menilai ketahanan model (*robustness*) dalam membedakan kelas-kelas yang ambigu. Metrik ini menghukum model yang memiliki disparitas besar antara Presisi dan *Recall* (misal: model yang hanya menebak satu kelas saja), sehingga memberikan penilaian yang lebih jujur terhadap kemampuan klasifikasi motif batik.

2.5 Tinjauan Pustaka Terkini dan Analisis Kesenjangan (Gap Analysis)

Berdasarkan penelusuran literatur sistematis pada periode 2020-2025, peta penelitian klasifikasi batik dapat dikelompokkan dan dianalisis sebagai berikut untuk mengidentifikasi posisi kebaruan penelitian ini serta menjustifikasi urgensi studi yang dilakukan.

2.5.1 Penelitian Klasifikasi Batik General (Antar-Rumpun)

Mayoritas penelitian yang ada saat ini masih berfokus pada klasifikasi antar-rumpun (*inter-class classification*). Sebagai contoh, penelitian seminal oleh Putri et al. (2021) menggunakan ResNet-50 untuk mengklasifikasikan 50 jenis batik dengan akurasi yang sangat tinggi (>90%). (Budimansyah et al., 2025) juga melakukan hal serupa dengan EfficientNet untuk 20 kelas batik. Meskipun angka akurasi tersebut impresif, dataset yang digunakan memiliki variasi bentuk yang sangat kontras (misal: membedakan garis miring Parang versus titik-titik Ceplok versus bentuk organik Megamendung).

- Pendekatan ini belum menguji batas kemampuan model dalam membedakan variasi halus (intra-kelas). Keberhasilan membedakan Parang dan Kawung tidak menjamin keberhasilan membedakan sub-varian Parang. Secara komputasi, jarak fitur (*feature distance*) antara Parang dan Kawung sangat jauh, sehingga *decision boundary* mudah dibentuk. Penelitian ini mengisi kekosongan tersebut dengan menantang model pada fitur yang berjarak sangat dekat.

2.5.2 Penelitian Klasifikasi Batik Biner dan Deteksi

Beberapa studi lain, seperti Siregar et al. (2023), melakukan penyederhanaan masalah melalui klasifikasi biner untuk mendeteksi "Parang" atau "Bukan Parang".

- Pendekatan ini efektif untuk deteksi keberadaan motif dalam citra luas, namun kurang memadai untuk tujuan katalogisasi museum digital yang membutuhkan identifikasi taksonomi spesifik. Mengetahui sebuah kain adalah "Parang" saja tidak cukup untuk menentukan nilai historis, filosofi, atau hierarki penggunaannya (Raja vs Rakyat). Ini adalah bentuk reduksi ontologis yang menghilangkan kekayaan data budaya. Sistem pelestarian yang cerdas membutuhkan kemampuan taksonomi yang lebih dalam (*fine-grained*), bukan sekadar deteksi biner.

2.5.3 Analisis Kesenjangan (Research Gap)

Berdasarkan sintesis matriks literatur tersebut, teridentifikasi beberapa kesenjangan penelitian yang krusial yang akan dijawab oleh penelitian ini:

Keterbatasan Studi Intra-Kelas (*The Intra-Class Gap*): Studi yang secara spesifik membandingkan performa arsitektur CNN pada level sub-motif (intra-kelas) Rumpun Parang masih sangat terbatas. Kebanyakan studi berhenti pada label "Parang" secara umum, mengabaikan kekayaan varian di dalamnya. Belum ada investigasi mendalam mengenai kegagalan model

pada level sub-motif ini: apakah model bingung karena tekstur, atau karena skala?

Komparasi Efisiensi vs Akurasi (The Efficiency Gap): Belum banyak studi lokal yang menyajikan analisis komparatif kuantitatif antara model berat (seperti ResNet) dan model ringan (seperti MobileNet) dalam konteks trade-off performa. Mayoritas riset hanya mengejar akurasi tertinggi tanpa mempertimbangkan biaya komputasi. Analisis ini sangat penting untuk menentukan kelayakan implementasi aplikasi batik pada perangkat mobile yang umum digunakan masyarakat Indonesia. Jika MobileNetV2 hanya kalah 1% akurasi namun 10x lebih cepat, maka ia lebih superior untuk pelestarian budaya yang inklusif.

Penelitian ini bertujuan mengisi kesenjangan tersebut dengan memberikan evaluasi empiris yang objektif, menggunakan metrik yang tepat, untuk menjawab tantangan kompleksitas *fine-grained* Batik Parang.

2.5.4 Penelitian Efisiensi Model (Mobile Classification

Penelitian oleh (Akbar et al., 2025) mengeksplorasi penggunaan MobileNetV2 untuk klasifikasi batik pada tiga kelas utama (Kawung, Mega Mendung, Parang). Studi ini membuktikan efisiensi waktu pelatihan yang ekstrem (18 menit vs 63 menit pada model besar).

- Meskipun efisien, studi ini menganggap "Parang" sebagai satu kelas tunggal (*lumped class*). Belum ada analisis mendalam mengenai apakah efisiensi MobileNetV2 harus dibayar dengan hilangnya akurasi pada detail *sub-motif* Parang.

Tabel 2.1: Matriks Sintesis Penelitian Terdahulu dan Kontribusi Penelitian

Peneliti & Tahun	**Metode / Model**	**Objek Studi**	**Temuan Utama**	**Keterbatasan (*Research Gap*)**
Putri et al. (2021)	Simple CNN & ResNet-50	50 Jenis Batik (General)	Akurasi 98% pada klasifikasi antar-rumpun (inter-class).	Pengujian bersifat *Coarse-Grained* (antar-rumpun). Tidak menguji variasi halus intra-rumpun.
Siregar et al. (2023)	CNN Standar	Batik Parang (Binary)	Akurasi 95% membedakan "Parang" vs "Non-Parang".	Reduksi ontologis: Hanya klasifikasi biner, tidak mampu membedakan jenis varian Parang.
Perdana et al. (2025)	Transfer Learning (MobileNet V2)	3 Kelas (Kawung, Mega Mendung, Parang)	MobileNet V2 efisien (training 18 menit) dengan akurasi 99%.	Menganggap "Parang" sebagai satu kelas tunggal (*lumped class*), mengabaikan varian intra-kelas.
Budimansyah et al. (2025)	EfficientNet	20 Kelas Batik	Akurasi 82.5%.	Menunjukkan penurunan performa pada kelas-kelas yang memiliki kemiripan visual tinggi.
Dani & Handayani (2024)	GLCM vs CNN	Batik Yogyakarta	CNN (94%) unggul signifikan atas GLCM (82%).	Membuktikan superioritas CNN, namun belum menyentuh aspek FGVC intra-kelas Parang.
Penelitian Ini	**Komparasi ResNet-50 vs MobileNet V2**	**Sub-Motif Parang (Rusak, Barong, Klitik)**	**Analisis *trade-off* F1-Score vs Efisiensi (FLOPS).**	**Mengisi celah klasifikasi detail intra-rumpun (*Fine-Grained*) dan studi kelayakan *mobile*.**

Sumber: Sintesis Penulis (2025) berdasarkan data literatur terverifikasi.

BAB 3: METODOLOGI PENELITIAN DAN PERANCANGAN SISTEM

3.1 Pendekatan Penelitian: Experimental Engineering

Penelitian ini mengadopsi paradigma *quantitative experimental engineering*, sebuah pendekatan sistematis yang menggabungkan prinsip rekayasa perangkat lunak dengan analisis statistik eksperimental yang ketat. Berbeda dengan penelitian korelasional yang hanya mengamati hubungan antar-variabel secara pasif, pendekatan ini melibatkan intervensi aktif dan manipulasi variabel bebas dalam hal ini adalah arsitektur model (*Deep Learning Architecture*), strategi augmentasi data (*Data Augmentation*), dan parameter pelatihan (*Hyperparameters*) untuk mengukur dampaknya secara presisi terhadap variabel terikat, yaitu performa klasifikasi (*Performance Metrics*).

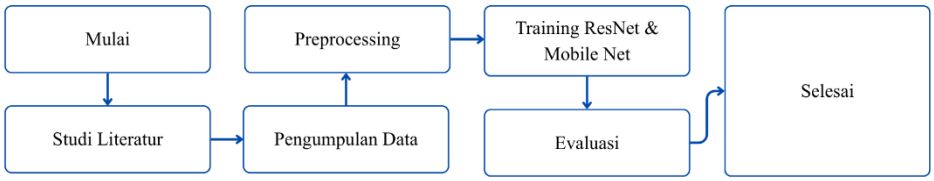
Landasan epistemologis dari metodologi ini adalah *falsifikasi empiris*. Penelitian ini tidak sekadar bertujuan untuk memvalidasi bahwa *Deep Learning* efektif untuk klasifikasi citra, melainkan untuk melakukan *stress-testing* terhadap dua arsitektur *state-of-the-art* (ResNet-50 dan MobileNetV2) dalam kondisi ekstrem: klasifikasi *fine-grained* pada dataset dengan varians intra-kelas yang tinggi namun varians antar-kelas yang rendah (isomorfis). Pendekatan ini dirancang untuk menjawab secara tuntas *Research Gap* yang telah diidentifikasi pada Bab 2, khususnya mengenai ketiadaan studi komparatif *head-to-head* pada level sub-motif batik yang memiliki kemiripan visual isomorfis (Budimansyah et al., 2025a).

Kerangka kerja operasional penelitian ini mengikuti alur kerja *End-to-End Computer Vision Pipeline* yang diadaptasi dari metodologi standar industri CRISP-DM (*Cross-Industry Standard Process for Data Mining*), namun dimodifikasi untuk konteks riset akademis *Deep Learning*. Pipeline ini terdiri dari lima tahapan sekuensial yang saling terintegrasi:

1. **Akuisisi & Kurasi Data (*Data Curation*):** Pengumpulan dan pembersihan data dari sumber sekunder (Zunafif, 2023; Dionisiusdh, 2023).

2. **Pra-pemrosesan & Augmentasi (*Preprocessing*):** Transformasi data mentah menjadi tensor siap-latih menggunakan teknik-teknik augmentasi lanjutan.
3. **Perancangan Arsitektur (*Model Design*):** Modifikasi *head* jaringan untuk *Transfer Learning* pada ResNet-50 dan MobileNetV2.
4. **Eksperimen & Pelatihan (*Training Loop*):** Eksekusi pelatihan model menggunakan akselerator GPU di lingkungan Google Colaboratory.
5. **Evaluasi & Analisis Komparatif (*Performance Audit*):** Pengukuran metrik dan analisis *trade-off* efisiensi dan akurasi.

$$Pipeline\ Penelitian = Data \rightarrow Preprocessing \rightarrow Model\ Design \rightarrow Training \rightarrow Evaluation$$



Gambar 3.1: Diagram Alir Metodologi Penelitian secara Keseluruhan.

3.2 Objek Penelitian dan Strategi Data

3.2.1 Strategi "Single-Family Dataset" untuk Isolasi Variabel

Penelitian ini menerapkan restriksi domain data yang ketat (hanya Rumpun Parang). Keputusan ini diambil untuk memitigasi bias klasifikasi bentuk (Shape Bias). Jika dataset dicampur dengan motif non-Parang (misal: Kawung), CNN cenderung mengambil 'jalan pintas' dengan mempelajari fitur bentuk geometri global (lingkaran vs garis) yang mudah. Dengan mengisolasi hanya pada Parang, model 'dipaksa' untuk mempelajari fitur tekstural dan kontekstual yang lebih dalam, sehingga validitas pengujian kemampuan fine-grained menjadi terjamin.

Keputusan metodologis ini sangat krusial dan didasarkan pada prinsip **isolasi variabel kesulitan**. Jika dataset dicampur dengan motif non-Parang, model *Deep Learning* akan cenderung mengambil "jalan pintas" dengan mempelajari fitur

bentuk global (*coarse features*) yang mudah dibedakan (misal: membedakan garis miring Parang vs lingkaran Kawung). Dengan membatasi dataset hanya pada Parang, kita memaksa model untuk belajar fitur diskriminatif lokal (*fine-grained features*) yang jauh lebih subtil, seperti perbedaan ketebalan garis, keberadaan ornamen *mlinjon*, dan frekuensi spasial motif. Strategi ini mengadopsi prinsip yang sama dengan dataset *benchmark* global CUB-200-2011 (Wen, n.d.) yang berfokus pada pembedaan spesies dalam satu keluarga burung.

3.2.2 Sumber Data Primer: Data Fusion Strategy

Salah satu tantangan terbesar dalam penelitian *Computer Vision* di bidang warisan budaya adalah kelangkaan data teranotasi (*data scarcity*). Untuk mengatasi hal ini, penelitian ini menerapkan strategi fusi data (*data fusion*) dengan menggabungkan dataset dari dua repositori publik terkurasi di platform Kaggle. Penggabungan ini bertujuan untuk meningkatkan volume data, memperkaya variabilitas visual, dan mencegah model mengalami *overfitting* terhadap karakteristik kamera atau fotografer tertentu (*source bias*).

Berdasarkan referensi dataset yang digunakan (Zunafif, 2023; Dionisiusdh, 2023), berikut adalah rincian komposisi data yang akan digunakan dalam penelitian:

Tabel 3.1: Spesifikasi dan Komposisi Dataset Hasil Fusi

Sumber Dataset	**Kontributor (Kaggle)**	**Jumlah Citra**	**Distribusi Kelas (Estimasi)**	**Karakteristik Visual**
Batik Parang	Zunafif (2023)	115 Citra	**Parang Rusak:** 65 citra **Non-Parang Rusak:** 50 citra	Citra tunggal, pencahayaan studio/terang, fokus pada motif utama, *clean background*.
Indonesian Batik Motifs	Dionisiusdh (2023)	44 Citra	**Parang:** 44 citra (campuran varian)	Variasi *angle* ekstrem, kain terlipat, pencahayaan alami, *in-the-wild*.
Total Awal	-	**159 Citra**	-	Campuran Heterogen (*Mixed Domain*)

Sumber: Analisis Penulis berdasarkan Metadata Dataset Kaggle (Zunafif, 2023; Dionisiusdh, 2023).

Meskipun jumlah total citra awal (159 citra) tergolong kecil untuk *Deep Learning*, hal ini justru menjadi justifikasi kuat untuk penggunaan teknik **Augmentasi Data** yang agresif dan **Transfer Learning** (Fadiyah Alya & Wibowo, 2023). Dataset CUB-200-2011 (Wen, n.d.) yang memiliki 11.788 citra untuk 200 kelas (rata-rata ~60 citra per kelas) menunjukkan bahwa jumlah sampel puluhan per kelas masih *feasible* untuk tugas *fine-grained* jika ditangani dengan benar.

3.2.3 Taksonomi Label Kelas (Ground Truth Validation)

Data mentah hasil fusi seringkali memiliki label yang tidak konsisten atau terlalu umum. Misalnya, Zunafif membedakan "Parang Rusak" dan "Non-Parang Rusak", sedangkan Dionisiusdh hanya melabeli "Parang". Oleh karena itu, tahap kurasi melibatkan anotasi ulang (*re-annotation*) secara manual. Berdasarkan tinjauan pustaka (Nuswantari, 2020) dan analisis visual, data dikelompokkan ke dalam tiga kelas taksonomi hierarkis:

1. **Kelas 0: Parang Rusak** (Ciri: Motif 'S' jalinan, ornamen mlinjon dominan).
2. **Kelas 1: Parang Barong** (Ciri: Motif besar/agung, garis tebal, skala makro).
3. **Kelas 2: Parang Klitik** (Ciri: Motif kecil/pipih, frekuensi spasial tinggi/rapat).

Proses validasi label dilakukan dengan merujuk pada literatur standar motif batik untuk meminimalkan *label noise* yang dapat mendegradasi performa model.

3.3 Pra-pemrosesan Data (Data Preprocessing)

Data mentah dari Kaggle tidak dapat langsung dimasukkan ke dalam CNN karena variasi dimensi dan distribusi intensitas piksel. Diperlukan serangkaian transformasi sistematis untuk menstandarisasi input tensor.

3.3.1 Standarisasi Dimensi (Resizing)

Setiap arsitektur CNN memiliki persyaratan dimensi input spasial tertentu.

- **ResNet-50:** Membutuhkan input 224 × 224 × 3 (RGB).
- **MobileNetV2:** Membutuhkan input 224 × 224 × 3 (RGB).

Citra asli yang memiliki resolusi bervariasi diubah ukurannya (*resized*) menjadi 224 × 224 piksel. Metode interpolasi yang digunakan adalah **Bicubic Interpolation**. Secara matematis, metode ini melibatkan 16 piksel tetangga terdekat (4x4) untuk menghitung nilai piksel baru, menghasilkan citra yang lebih halus dan mempertahankan detail tepi (*edge details*) lebih baik dibandingkan metode *Nearest Neighbor* atau *Bilinear*. Ini krusial untuk mempertahankan detail isen-isen batik yang kecil saat dilakukan pengecilan ukuran (*downscaling*).

3.3.2 Normalisasi Statistik (Pixel Normalization)

Nilai piksel asli citra digital berada pada rentang [0, 255]. Agar proses konvergensi gradien lebih cepat dan stabil selama pelatihan, nilai ini dinormalisasi. Karena menggunakan *Transfer Learning* dari bobot ImageNet, normalisasi mengikuti standar distribusi data ImageNet (He et al., 2016):

$$X_norm = (X - \mu) / \sigma$$

Di mana nilai rata-rata (μ) adalah [0.485, 0.456, 0.406] dan nilai standar deviasi (σ) adalah [0.229, 0.224, 0.225] untuk masing-masing kanal RGB. Langkah ini krusial agar bobot pre-trained dapat bekerja secara efektif ketika diterapkan pada domain data yang baru.

3.3.3 Strategi Pembagian Data (Splitting Strategy)

Dataset dibagi menggunakan teknik *Stratified Random Sampling* untuk menjaga proporsi kelas yang seimbang di setiap subset, mencegah bias evaluasi pada kelas mayoritas.

- **Training Set (80%):** Digunakan untuk melatih bobot model (*backpropagation*).
- **Validation Set (10%):** Digunakan untuk evaluasi *real-time* selama pelatihan dan penentuan *hyperparameter*.
- **Test Set (10%):** Data "buta" yang tidak pernah dilihat model selama pelatihan, digunakan hanya untuk evaluasi akhir.

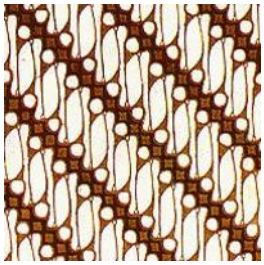
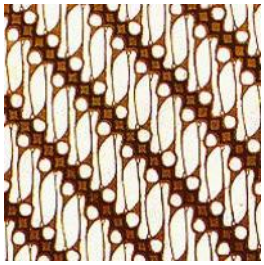
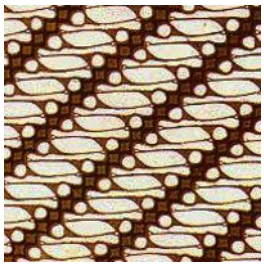
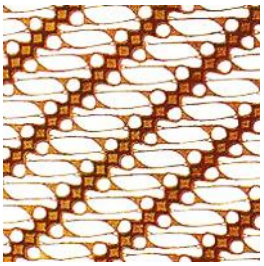
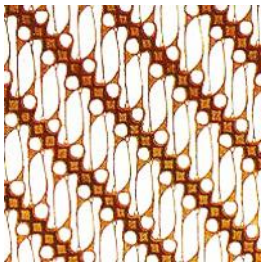
3.4 Skenario Augmentasi Data (Data Augmentation)

Mengingat total dataset gabungan hanya berkisar 159 citra, risiko *overfitting* sangat tinggi. Sebagaimana dibuktikan oleh **Negara et al. (2021)**, augmentasi data adalah solusi wajib untuk meningkatkan performa ResNet pada dataset batik yang terbatas. Penelitian ini merancang skenario augmentasi geometris dan intensitas yang mensimulasikan kondisi nyata pengambilan foto.

Tabel 3.2: Konfigurasi Parameter Augmentasi Data

Teknik Augmentasi	Parameter Setting	Justifikasi Teoretis & Praktis
Random Rotation	±30 derajat	Kain batik tidak memiliki orientasi "atas-bawah" yang mutlak (bisa dipakai miring). Model harus belajar invarian rotasi.
Random Horizontal Flip	P = 0.5	Motif batik seringkali simetris atau dicetak bolak-balik. Memperkaya variasi arah hadap.
Random Vertical Flip	P = 0.5	Relevan untuk motif geometris berulang yang tidak memiliki orientasi vertikal kaku.
Color Jitter	Brightness: ±0.2 Contrast: ±0.2	Mensimulasikan perbedaan pencahayaan museum (redup) vs luar ruangan (terang) serta perbedaan kualitas pewarnaan kain (pudar).
Zoom/Shear	Range: 0.2	Mensimulasikan efek perspektif saat foto diambil dari sudut miring, bukan tegak lurus (*affine transformation*).

Sumber: Adaptasi dari teknik Augmentasi Negara et al. (2021) dan Bisong (2019).

		
Rotasi Kiri 90	Flip Horizontal	Rotasi Kanan 90
		
Rotasi 180	Citra Asli	Flip Vertical
		
Gelap	Terang	Gabungan (Terang & Rotasi)

Tabel 3.3: Visualisasi hasil augmentasi data pada satu sampel citra Parang Rusak. Teknik ini memperbanyak variasi data latih secara sintetik.

3.5 Perancangan Arsitektur Model (Transfer Learning)

Penelitian ini tidak membangun CNN dari nol (*scratch*), melainkan memodifikasi arsitektur *state-of-the-art* menggunakan teknik *Transfer Learning*

(Pan & Yang, 2010; Fadiyah Alya & Wibowo, 2023). Pendekatan ini terbukti efektif untuk dataset batik dengan jumlah sampel terbatas (Perdana et al., 2025).

3.5.1 Modifikasi Arsitektur ResNet-50

ResNet-50 asli (He et al., 2016) didesain untuk 1000 kelas ImageNet. Untuk kasus batik ini, dilakukan modifikasi pada bagian *Head* (lapisan klasifikasi):

1. **Base Model:** ResNet-50 tanpa lapisan *Top* (Fully Connected). Bobot dimuat dari ImageNet.
2. **Global Average Pooling (GAP):** Menggantikan *Flatten* untuk mengurangi jumlah parameter secara drastis dan mencegah *overfitting*. GAP merata-ratakan *feature map* 7 × 7 × 2048 menjadi vektor 1 × 2048. Desain Classifier Head untuk Mitigasi Overfitting. Mengingat rasio jumlah parameter ResNet-50 (~25 juta) terhadap jumlah data latih (~120 citra) yang sangat tidak seimbang, risiko overfitting sangat tinggi. Oleh karena itu, arsitektur dimodifikasi dengan pendekatan regularisasi agresif:

    - **Substitusi Flatten dengan GAP:** Mengurangi dimensi tensor secara drastis menjadi vektor rata-rata 1 × 2048. Ini memaksa model untuk mengenali motif secara holistik (keseluruhan kain) alih-alih terpaku pada posisi spasial tertentu.
    - **Dropout Diferensial:** ResNet-50 diberi *dropout rate* tinggi (0.5) sebagai penalti berat karena kapasitasnya yang besar, sementara MobileNetV2 diberi rate moderat (0.3) untuk menjaga aliran informasi pada model yang sudah terkompresi.

3. **Dropout Layer:** Ditambahkan dengan *rate* 0.5. Ini mematikan 50% neuron secara acak selama pelatihan untuk memaksa jaringan belajar fitur yang *robust* (tidak bergantung pada satu neuron saja).
4. **Dense Output Layer:** Lapisan akhir dengan 3 neuron (sesuai jumlah kelas: Rusak, Barong, Klitik) menggunakan fungsi aktivasi **Softmax**.

3.5.2 Modifikasi Arsitektur MobileNetV2

MobileNetV2 (Sandler et al., 2018) dimodifikasi serupa, namun dengan fokus mempertahankan efisiensi komputasi:

1. **Base Model:** MobileNetV2 dengan bobot ImageNet. Fitur keluaran berdimensi 1 ×1280 setelah GAP.
2. **Dropout Layer:** Rate 0.3 (lebih rendah karena model ini sudah ringkas, risiko *overfitting* lebih kecil dibanding ResNet yang besar).
3. **Dense Output Layer:** 3 neuron dengan fungsi aktivasi **Softmax**.

[TEMPATKAN GAMBAR 3.4 DI SINI] *Rekomendasi Visual:* Diagram blok perbandingan arsitektur modifikasi.

- *Kiri:* ResNet-50 Base -> GAP -> Dropout(0.5) -> Dense(3, Softmax).
- *Kanan:* MobileNetV2 Base -> GAP -> Dropout(0.3) -> Dense(3, Softmax). *Caption:* **Gambar 3.4:** Skema modifikasi arsitektur Transfer Learning untuk ResNet-50 dan MobileNetV2. Lapisan *Base* dibekukan (frozen) pada tahap awal, kemudian dibuka (unfrozen) pada tahap *fine-tuning*.

3.5.3 Strategi Pelatihan (Training Strategy)

Pelatihan dilakukan dalam dua fase bertingkat (*Two-Stage Training*) untuk menjaga stabilitas bobot, merujuk pada praktik terbaik *Transfer Learning* (Akbar et al., 2025):

- **Fase 1: Feature Extraction (Warm-up).** Bekukan (*freeze*) seluruh *Base Model*. Hanya latih lapisan *Head* (Dense) selama 10 epoch dengan *learning rate* standar 0,001. Tujuannya agar bobot acak pada *Head* tidak merusak fitur *pre-trained* yang sudah bagus.
- **Fase 2: Fine-Tuning.** Cairkan (*unfreeze*) sebagian lapisan akhir dari *Base Model* (misal: blok residual terakhir pada ResNet). Latih kembali dengan *learning rate* yang sangat kecil 0,00001 agar model beradaptasi dengan fitur

spesifik batik tanpa melupakan pengetahuan dasarnya (*catastrophic forgetting*).

3.6 Lingkungan Implementasi Sistem: Google Colaboratory

Eksperimen komputasi dilakukan di lingkungan *cloud* untuk memastikan ketersediaan sumber daya akselerasi perangkat keras yang memadai dan konsisten. Penelitian ini memanfaatkan **Google Colaboratory** (Colab) sebagaimana direkomendasikan oleh **Bisong (2019)** sebagai platform yang ideal untuk eksperimen *Deep Learning* yang efisien.

Tabel 3.3: Spesifikasi Lingkungan Eksperimen

Komponen	Spesifikasi / Tools	Keterangan Fungsional
Platform	Google Colaboratory	Lingkungan riset berbasis Jupyter Notebook di Cloud.
GPU	NVIDIA Tesla T4	Akselerator dengan 16GB VRAM untuk komputasi matriks paralel (Tensor). Mempercepat pelatihan ResNet secara signifikan.
RAM	12 GB+	Memori sistem untuk memuat *batch* dataset ke dalam *buffer* tanpa *swapping*.
Bahasa	Python 3.10+	Bahasa pemrograman standar *de facto* untuk *Data Science*.

Framework	TensorFlow 2.x / Keras	Pustaka *Deep Learning* tingkat tinggi untuk abstraksi model yang efisien.
Library	NumPy, Pandas, Matplotlib, Scikit-learn	Pustaka pendukung untuk manipulasi matriks, pemrosesan data, dan visualisasi metrik evaluasi.

Sumber: Dokumentasi Teknis Google Colab dan Bisong (2019).

Penggunaan GPU T4 di Google Colab memungkinkan pelatihan model yang kompleks seperti ResNet-50 diselesaikan dalam hitungan jam, bukan hari, memfasilitasi iterasi eksperimen yang lebih cepat.

3.7 Metrik Evaluasi dan Analisis Performa

Untuk menjawab rumusan masalah secara komprehensif, evaluasi tidak hanya berhenti pada akurasi global. Penelitian ini menggunakan pendekatan *Multi-Metric Evaluation* untuk mendapatkan gambaran performa yang holistik dan jujur.

3.7.1 Confusion Matrix

Dasar dari semua metrik klasifikasi. Matriks berukuran 3 × 3 yang memetakan prediksi model (sumbu X) terhadap kelas asli (sumbu Y).

- **Diagonal Utama:** Menunjukkan prediksi benar (*True Positive*).
- **Elemen Luar Diagonal:** Menunjukkan kesalahan klasifikasi (*misclassification*). Ini krusial untuk menganalisis pola kesalahan spesifik: *Apakah model sering tertukar antara Parang Rusak dan Parang Barong akibat kemiripan bentuk?*

3.7.2 Metrik Kuantitatif Utama

Berdasarkan elemen *Confusion Matrix* (TP, TN, FP, FN), dihitung metrik standar berikut (**Budimansyah et al., 2025a**):

1. **Akurasi (Accuracy):** Rasio prediksi benar terhadap total data. Memberikan gambaran performa global.

$$Accuracy = \frac{TP + TN}{Total\ Sampel}$$

2. **Presisi (Precision):** Tingkat kepercayaan prediksi positif $\frac{TP+TN}{Total\ Sampel}$. Penting untuk meminimalkan *False Positive* (misal: salah melabeli batik biasa sebagai batik langka).
3. **Recall (Sensitivity):** Kemampuan menemukan kembali seluruh instansi kelas $\frac{TP}{TP+FN}$. Penting untuk aspek pelestarian agar tidak ada varian motif yang terlewat.
4. **F1-Score:** Rata-rata harmonik antara Presisi dan Recall. Ini adalah metrik penyeimbang yang paling kritis untuk dataset yang mungkin tidak seimbang (*imbalanced*). $F1 = 2 \times \frac{(Precision\ X\ Recall)}{(Precision + Recall)}$

3.7.3 Metrik Efisiensi Komputasi

Karena salah satu tujuan penelitian adalah membandingkan kelayakan implementasi *mobile* (**Perdana et al., 2025**), dua metrik efisiensi diukur:

1. **Waktu Pelatihan (Training Time):** Rata-rata durasi per *epoch* (detik).
2. **Ukuran Model (Model Size):** Ukuran file model terkompresi (.h5 atau .tflite) dalam Megabyte (MB).
3. **Inference Latency:** Waktu yang dibutuhkan model untuk memprediksi satu citra (milidetik).

$$Efficiency\ Score = \frac{Accuracy}{(Model\ Size \times\ Latency)}$$

Analisis ini akan digunakan untuk menjawab pertanyaan penelitian mengenai *trade-off*: Apakah peningkatan akurasi marjinal pada ResNet-50 sepadan dengan biaya komputasi yang jauh lebih besar dibandingkan MobileNetV2?

3.7.4. Protokol Analisis Kesalahan (*Error Analysis Protocol*)

Selain metrik kuantitatif, penelitian ini akan melakukan audit kualitatif terhadap *misclassification* menggunakan *Confusion Matrix*. Analisis akan difokuskan pada dua tipe kesalahan:

- **Confusion Isomorfis:** Kesalahan membedakan Parang Rusak vs Parang Barong (mengindikasikan kegagalan model menangkap fitur skala/ketebalan).
- **Confusion Tekstural:** Kesalahan membedakan Parang Klitik (mengindikasikan kegagalan menangkap frekuensi spasial/kerapatan). Langkah ini bertujuan untuk membedah *black-box* model dan memahami 'mengapa' satu arsitektur gagal dibanding yang lain.

DAFTAR PUSTAKA

Wen, X. (n.d.). CUB-200-2011 [Data set]. Kaggle. https://www.kaggle.com/datasets/wenewone/cub2002011

Zunafif. (2023). Batik Parang [Data set]. Kaggle. https://www.kaggle.com/datasets/zunafif/batik-parang

Dionisiusdh. (2023). Indonesian Batik Motifs [Data set]. Kaggle. https://www.kaggle.com/datasets/dionisiusdh/indonesian-batik-motifs

Akbar, A., Perdana, M., Fajar, M., & Muis Mappalotteng, A. (n.d.). *INTERNATIONAL JOURNAL ON INFORMATICS VISUALIZATION journal homepage : www.joiv.org/index.php/joiv INTERNATIONAL JOURNAL ON INFORMATICS VISUALIZATION Enhancing Batik Classification Leveraging CNN Models and Transfer Learning*. www.joiv.org/index.php/joiv

Akbar, A., Perdana, M., Fajar, M., & Muis Mappalotteng, A. (2025). *INTERNATIONAL JOURNAL ON INFORMATICS VISUALIZATION journal homepage : www.joiv.org/index.php/joiv INTERNATIONAL JOURNAL ON INFORMATICS VISUALIZATION Enhancing Batik Classification Leveraging CNN Models and Transfer Learning*. www.joiv.org/index.php/joiv

Ananda, R. D., & Irma, H. (2024). *KLASIFIKASI MOTIF BATIK YOGYAKARTA MENGGUNAKAN METODE GLCM DAN CNN*.

Angginy Akhirunnisa Siregar, Citra Citra, Dechy Deswita Indriani.S, & Gifari Dhaffa Prawira Sianturi. (2023). Klasifikasi Batik Parang Menggunakan Convolutional Neural Network (CNN). *Populer: Jurnal Penelitian Mahasiswa*, *3*(1), 62–69. https://doi.org/10.58192/populer.v3i1.1666

Anggoro, D. A., Marzuki, A. A. T., & Supriyanti, W. (2024). Classification of Solo Batik patterns using deep learning convolutional neural networks algorithm. *Telkomnika (Telecommunication Computing Electronics and Control)*, *22*(1), 232–240. https://doi.org/10.12928/TELKOMNIKA.v22i1.24598

Azmi, K., Defit, S., & Putra Indonesia YPTK Padang Jl Raya Lubuk Begalung-Padang-Sumatera Barat, U. (n.d.). *Implementasi Convolutional Neural Network (CNN) Untuk Klasifikasi Batik Tanah Liat Sumatera Barat*. *16*(1), 2023.

Bisong, E. (2019). Building Machine Learning and Deep Learning Models on Google Cloud Platform: A Comprehensive Guide for Beginners. In *Building Machine Learning and Deep Learning Models on Google Cloud Platform: A Comprehensive Guide for Beginners*. Apress Media LLC. https://doi.org/10.1007/978-1-4842-4470-8

Budimansyah, E., Ariawan, D., Maulana, R. D., Yudha, W. R., & Munsarif, M. (2025a). KLASIFIKASI MOTIF BATIK INDONESIA MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK (CNN). *JURNAL KOMPUTER DAN TEKNOLOGI INFORMASI*, *3*(2). https://doi.org/10.26714/jkti.v3i2.18627

Budimansyah, E., Ariawan, D., Maulana, R. D., Yudha, W. R., & Munsarif, M. (2025b). KLASIFIKASI MOTIF BATIK INDONESIA MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK (CNN). *JURNAL KOMPUTER DAN TEKNOLOGI INFORMASI*, *3*(2). https://doi.org/10.26714/jkti.v3i2.18627

Fadiyah Alya, R., & Wibowo, M. (2023). *CLASSIFICATION OF BATIK MOTIF USING TRANSFER LEARNING ON CONVOLUTIONAL NEURAL NETWORK (CNN)*. *4*(1), 161–170. https://doi.org/10.20884/1.jutif.2023.4.1.564

Gede, D., Meranggi, T., Yudistira, N., & Sari, Y. A. (n.d.). *INTERNATIONAL JOURNAL ON INFORMATICS VISUALIZATION journal homepage : www.joiv.org/index.php/joiv INTERNATIONAL JOURNAL ON INFORMATICS VISUALIZATION Batik Classification Using Convolutional Neural Network with Data Improvements*. www.joiv.org/index.php/joiv

HARALICK, R. M. , K. SHANMUGAM, & ITS'HAK DINSTEIN. (1973). *Textural Features for Image Classification*.

Hardirega, A. and J. I. and M. (2024). *IMPLEMENTASI CONVOLUTIONAL NEURAL NETWORK (CNN) KLASIFIKASI MOTIF BATIK MENGGUNAKAN EFFICIENTNET-B1*.

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, *2016-December*, 770–778. https://doi.org/10.1109/CVPR.2016.90

Lowe, D. G. (2004). Distinctive Image Features from Scale-Invariant Keypoints. In *International Journal of Computer Vision* (Vol. 60, Issue 2).

Muriagista, A., & Kurniadi, D. (n.d.). *Jurnal Rekayasa Sistem Informasi dan Teknologi Volume 2, No 4 Mei 2025 e-ISSN : 3025-888X IMPLEMENTASI ARSITEKTUR RESNET50 PADA KLASIFIKASI MOTIF BATIK INDONESIA MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK (CNN)*.

Negara, B. S., Satria, E., Sanjaya, S., & Dwi Santoso, D. R. (2021, July 4). ResNet-50 for Classifying Indonesian Batik with Data Augmentation. *2021 International Congress of Advanced Technology and Engineering, ICOTEN 2021*. https://doi.org/10.1109/ICOTEN52080.2021.9493488

Pan, S. J., & Yang, Q. (2010). A survey on transfer learning. In *IEEE Transactions on Knowledge and Data Engineering* (Vol. 22, Issue 10, pp. 1345–1359). https://doi.org/10.1109/TKDE.2009.191

Putri, Y. A., Azhar, Y., & Minarno, A. E. (2021). Klasifikasi Jenis Batik Menggunakan Algoritma Convolutional Neural Network. *REPOSITOR*, *3*(2), 199–206.

Safira Putri Wulandari, R. W. (2020). *Penggunaan Machine Learning Untuk Pengenalan Pola Batik Parang Menggunakan PCA {Principal Component Analysis)*.

Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., & Chen, L. C. (2018). MobileNetV2: Inverted Residuals and Linear Bottlenecks. *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, 4510–4520. https://doi.org/10.1109/CVPR.2018.00474

Wah, C., Branson, S., Welinder, P., Perona, P., & Belongie, S. (2011). *The Caltech-UCSD Birds-200-2011 Dataset*. http://www.birdfieldguide.com